Exploratory Data Analysis (EDA) Report

Analiza eksploracyjna danych tabularnych i tekstowych

Projekt: modelowanie przepływu pacjentów między praktykami GP a opieką szpitalną w Szkocji

Autor: Antoni Kostuj

Spis treści

Spis treści ..... **Błąd! Nie zdefiniowano zakładki.**
1. Wprowadzenie 3
Główne pytania EDA 3
2. Opis danych 3
2.1. Dane tabularne (PHS GP practice list sizes) 3
2.2. Dane tekstowe (raporty/biuletyny) 3
3. Metodyka i narzędzia 5
3.1. Środowisko 5
3.2. Preprocessing przed EDA 5
4. Wyniki EDA – dane tabularne 6
4.1. Jakość danych 6
4.2. Zakres czasowy i struktura 6
4.3. Statystyki opisowe i rozkłady wielkości praktyk 7
4.4. Korelacje między grupami wiekowymi 9
4.5. Wartości odstające (IQR) 9
5. Wyniki EDA – dane tekstowe 10
5.1. Statystyki korpusu 10
5.2. Najczęstsze tokeny i bigramy 11
5.3. TF-IDF – słowa kluczowe 12
5.4. Modelowanie tematów (LDA) 12
5.5. Szum i artefakty 12
6. Interpretacja w kontekście pracy dyplomowej 13
7. Rekomendacje i kolejne kroki 14
7.1. Preprocessing i przygotowanie cech 14
7.2. Tekst 14

1. Wprowadzenie

Celem EDA jest zrozumienie struktury i jakości danych przed budową modeli oraz przed przygotowaniem cech do analizy przepływów pacjentów. W raporcie opisano kluczowe właściwości danych tabularnych (liczebności list pacjentów w praktykach GP) oraz danych tekstowych (sekcje z raportów), z naciskiem na wykrycie braków, niespójności, wartości odstających oraz potencjalnych ryzyk dla dalszego modelowania.

Główne pytania EDA

- Jaka jest kompletność i spójność danych (braki, duplikaty, błędne wartości)?
- Jak wygląda rozkład wielkości praktyk GP oraz zmiany w czasie (także wg płci)?
- Czy istnieją wartości odstające, które mogą zaburzać estymacje i wizualizacje?
- Jakie cechy demograficzne są współzależne (korelacje między grupami wiekowymi)?
- Jakie są podstawowe właściwości korpusu tekstowego oraz dominujące terminy i tematy?

2. Opis danych

2.1. Dane tabularne (PHS GP practice list sizes)

Zbiór danych zawiera obserwacje kwartalne dotyczące liczby pacjentów zapisanych do praktyk GP w Szkocji, z podziałem na płeć oraz grupy wiekowe. Po wczytaniu: 83391 wierszy i 23 kolumn. Zakres czasu: 2014-01-01 – 2021-07-01. Liczba unikalnych praktyk: 1082. Kategorie płci: 3. Jednostki terytorialne: HB = 16, HSCP = 33.

Atrybut	Opis (skrót)
Date	data obserwacji (kwartał)
PracticeCode	identyfikator praktyki
HB	Health Board
HSCP	Health and Social Care Partnership
Sex	All / Male / Female
AllAges	liczba pacjentów (wszyscy)
Ages0to4 ... Ages85plus	liczebności w grupach wiekowych

2.2. Dane tekstowe (raporty/biuletyny)

Dane tekstowe pochodzą z wybranych dokumentów tematycznie powiązanych z systemem ochrony zdrowia (raport/biuletyn). Tekst został podzielony na sekcje (jednostki analizy), a

następnie znormalizowany i stokenizowany w celu analizy częstości, TF-IDF oraz modelowania tematów.

Źródło	Liczba znaków (po ekstrakcji)
public_health_bulletin_2025_01	16647
gp_workforce_survey_2022	40785

3. Metodyka i narzędzia

3.1. Środowisko

- Python (Jupyter/Colab).
- pandas i numpy – wczytanie, czyszczenie i statystyki opisowe.
- matplotlib – wizualizacje (histogramy, boxploty, heatmapy).
- nltk – tokenizacja.
- scikit-learn – TF-IDF i wektoryzacja.
- gensim lub równoważne – proste modelowanie tematów (LDA), jeśli użyte w notatniku.

3.2. Preprocessing przed EDA

- Konwersja kolumny Date do typu daty; kontrola zakresu czasowego.
- Usunięcie lub ignorowanie kolumn jakościowych QF z bardzo wysokim udziałem braków.
- Rozdzielenie danych zagregowanych (Sex = All) oraz danych wg płci (Male/Female).
- Dla tekstu: normalizacja (lowercase), czyszczenie znaków, tokenizacja, filtracja stop-słów (jeśli zastosowano).
- Podział dokumentów na sekcje jako jednostki analizy (w celu zwiększenia liczby obserwacji tekstowych).

4. Wyniki EDA – dane tabularne

4.1. Jakość danych

Kolumny z sufiksem QF zawierają niemal wyłącznie braki (około 99%). Zmienne ilościowe (liczebności grup wiekowych) mają znikomy poziom braków (<0,2%). Nie wykryto duplikatów obserwacji.

```
Top missing columns (%):
Ages65To74QF    99.088631
Ages85PlusQF    99.088631
Ages75To84QF    99.088631
Ages15To24QF    99.088631
Ages25To44QF    99.088631
Ages5To14QF     99.088631
Ages0To4QF      99.088631
Ages45To64QF    99.088631
SexQF           66.663069
Ages25to44       0.143900
Ages15to24       0.143900
Ages65to74       0.143900
Ages45to64       0.143900
Ages0to4         0.143900
Ages5to14        0.143900
Ages75to84       0.143900
Ages85plus       0.143900
AllAges          0.019187
HSCP             0.000000
Date             0.000000
Sex              0.000000
PracticeCode     0.000000
HB               0.000000
dtype: float64
duplicated rows:  0
```

4.2. Zakres czasowy i struktura

- Zakres dat: 2014-01-01 – 2021-07-01.
- Niekompletny zestaw kategorii płci dla (Date, PracticeCode): 9 przypadków (np. brak jednej z kategorii).

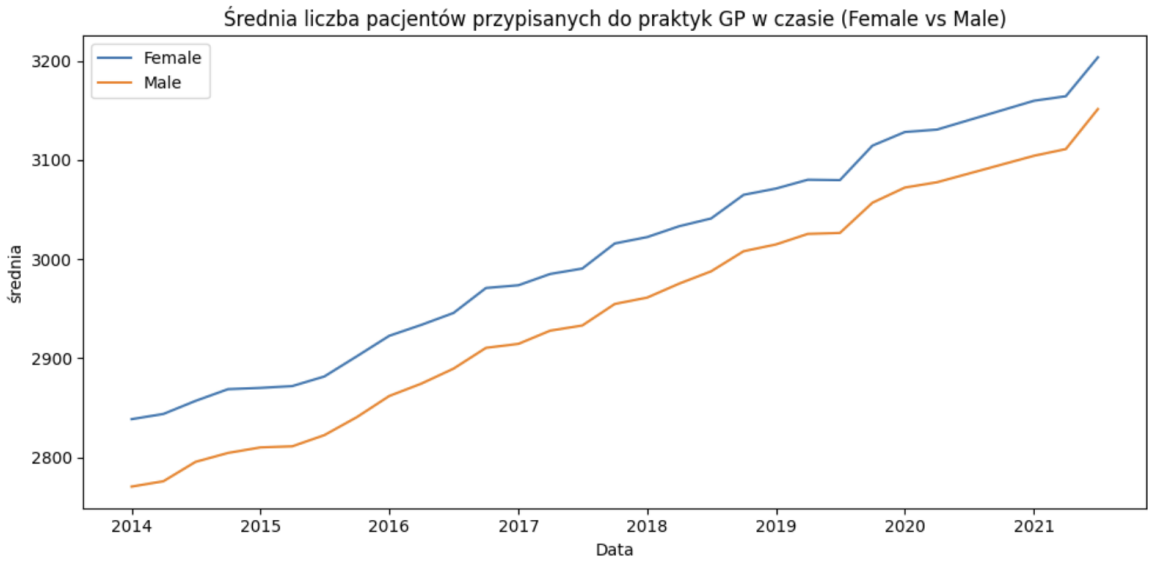

4.3. Statystyki opisowe i rozkłady wielkości praktyk

Miara	AllAges (Sex=All)
Liczba obserwacji	27800
Średnia	5931.15
Odchylenie std.	3720.68
Min	0
25%	3173
Mediana (50%)	5494.5
75%	8180.25
Max	48657

- Wykryto 2 obserwacje z AllAges = 0 (ok. 0,007%); do decyzji: usunąć lub sprawdzić źródło błędu.
- Rozkład wielkości praktyk jest prawoskośny (nieliczne bardzo duże praktyki).

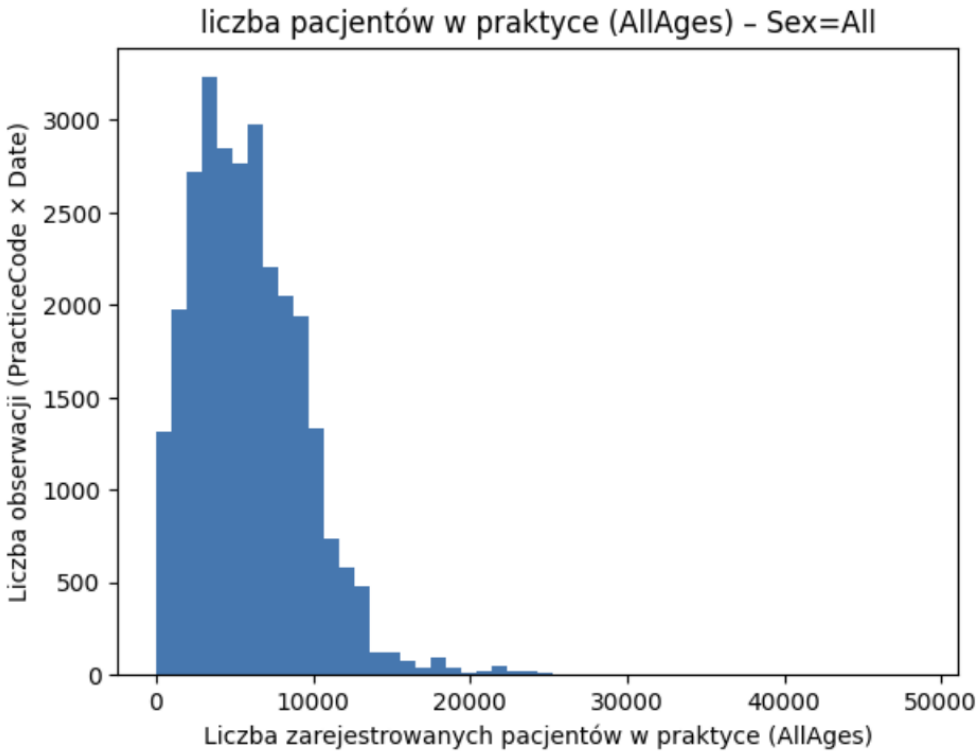
liczba pacjentów w praktyce (AllAges) – Sex=All
Liczba obserwacji (PracticeCode × Date)
3000
2500
2000
1500
1000
500
0
0
10000
20000
30000
40000
50000
Liczba zarejestrowanych pacjentów w praktyce (AllAges)

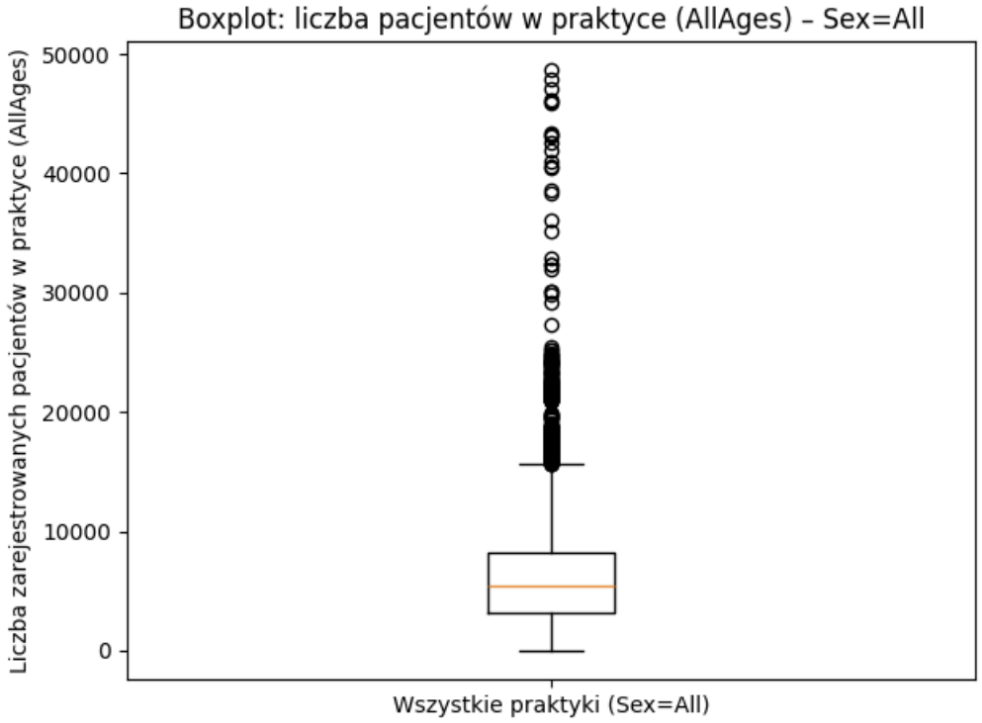
Boxplot: liczba pacjentów w praktyce (AllAges) – Sex=All
Liczba zarejestrowanych pacjentów w praktyce (AllAges)
50000
40000
30000
20000
10000
0
Wszystkie praktyki (Sex=All)

4.4. Korelacje między grupami wiekowymi

Do analizy korelacji przygotowano 9 zmiennych liczebności (AllAges oraz osiem grup wiekowych). Macierz korelacji pomaga wykryć współliniowość i wskazuje, które cechy mogą być redundantne w modelu.

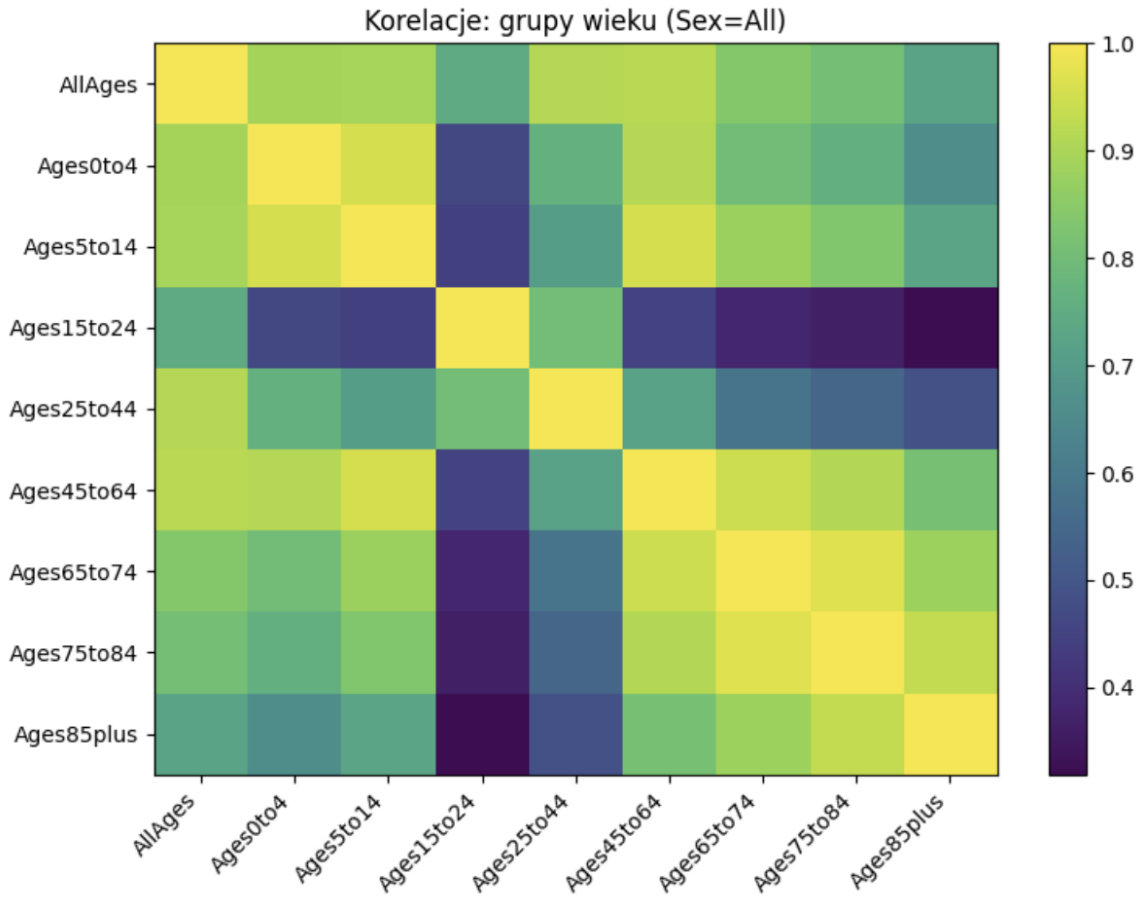

4.5. Wartości odstające (IQR)

- Granice IQR dla AllAges: dolna = -4338.0, górna = 15692.0.
- Liczba obserwacji uznanych za odstające: 375.
- Wartości odstające wynikają głównie z bardzo dużych praktyk;

	Date	PracticeCode	HB	HSCP	AllAges
81792	2021-07-01	43576	S08000031	S37000034	48657.0
79023	2021-04-01	43576	S08000031	S37000034	47877.0
76248	2021-01-01	43576	S08000031	S37000034	47049.0
70665	2020-01-01	43576	S08000031	S37000034	46215.0
73461	2020-04-01	43576	S08000031	S37000034	46086.0
67866	2019-10-01	43576	S08000031	S37000034	45912.0
59406	2019-01-01	43576	S08000021	S37000034	43368.0
62232	2019-04-01	43576	S08000021	S37000034	43222.0
65055	2019-07-01	43576	S08000031	S37000034	43164.0
56574	2018-10-01	43576	S08000021	S37000034	42631.0

5. Wyniki EDA – dane tekstowe

5.1. Statystyki korpusu

- Liczba dokumentów/sekcji: 14.
- Liczba unikalnych słów (słownik): 1127.
- Średnia długość dokumentu (tokeny): 290.3.
- Mediana długości dokumentu (tokeny): 114.
- Krótkie sekcje (<100 tokenów): 5 (potencjalnie mniej informacyjne).

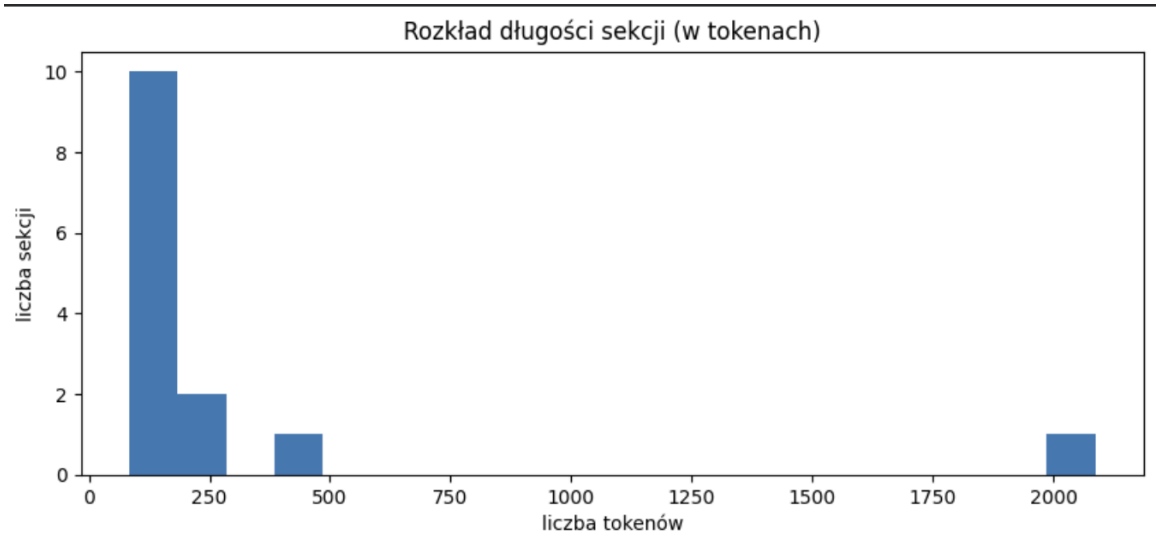

5.2. Najczęstsze tokeny i bigramy

	token	count
0	wte	130
1	headcount	93
2	estimated	91
3	data	83
4	nhs	57
5	practice	55
6	general	50
7	practices	50
8	nurse	50
9	survey	47
10	health	41
11	scotland	40
12	per	35
13	sessions	35
14	care	34
15	nurses	34
16	board	29
17	information	28

	bigram	count
0	estimated wte	41
1	general practice	34
2	nhs board	22
3	wte per	22
4	headcount estimated	18
5	headcount wte	15
6	estimated headcount	14
7	responding practices	14
8	primary care	13
9	practice nurse	13
10	general practices	12
11	see methodology	11
12	methodology section	11
13	headcount npccd	11
14	non clinical	11
15	practices scotland	10
16	age group	10
17	wte defined	10
18	weekly contracted	9
19	public health	8

5.3. TF-IDF – słowa kluczowe

Termin	Średni TF-IDF
gp	0.1058
wte	0.0861
data	0.0788
2025	0.0720
headcount	0.0640

- TF-IDF wskazuje terminy silnie charakterystyczne dla sekcji (np. skróty branżowe i metryki zatrudnienia).
- Jeżeli celem jest łączenie informacji tekstowych z danymi tabularnymi, TF-IDF może zostać użyty do budowy cech (embeddingi / tematy / słowa kluczowe).

5.4. Modelowanie tematów (LDA)

Zastosowano proste modelowanie tematów (LDA) w celu identyfikacji dominujących wątków w korpusie. Wynik w postaci listy słów o największych wagach dla tematów pozwala interpretować, czy dokumenty dotyczą np. zasobów kadrowych, zdrowia psychicznego, statystyk publicznych itp.

```
Topic 0:
0.040*"statistics" + 0.018*"people" + 0.014*"nhs" + 0.014*"number" + 0.014*"public" + 0.014*"females" + 0.014*"services" + 0.014*"website" + 0.014*"official" + 0.014*"inequalities"

Topic 1:
0.029*"mental" + 0.026*"people" + 0.023*"release" + 0.020*"women" + 0.017*"food" + 0.017*"study" + 0.013*"working" + 0.013*"new" + 0.013*"statistics" + 0.010*"care"

Topic 2:
0.056*"wte" + 0.040*"headcount" + 0.039*"estimated" + 0.023*"practice" + 0.022*"nhs" + 0.022*"practices" + 0.022*"nurse" + 0.021*"general" + 0.020*"survey" + 0.015*"sessions"

Topic 3:
0.048*"information" + 0.018*"nhs" + 0.018*"made" + 0.017*"media" + 0.016*"topic" + 0.016*"service" + 0.016*"accuracy" + 0.015*"make" + 0.014*"date" + 0.012*"relevant"
```

5.5. Szum i artefakty

- Wykryto niewielki udział sekcji z artefaktami po ekstrakcji (np. elementy nawigacyjne/źródłowe) – szczególnie w jednym ze źródeł.
- Rekomendowane: dodatkowe reguły czyszczenia (usuwanie nagłówków/stopki, linków, krótkich linii).

6. Interpretacja w kontekście pracy dyplomowej

- Dane tabularne są wystarczająco kompletne do budowy cech demograficznych na poziomie praktyki i okresu czasu; największym ograniczeniem są kolumny QF (praktycznie puste).
- Nieliczne rekordy z AllAges = 0 oraz niekompletne zestawy płci wymagają jawnej obsługi w pipeline (filtr/uzupełnienie), aby nie zaburzać agregacji.
- Silna prawoskośność rozkładu wielkości praktyk oraz obecność outlierów sugerują użycie transformacji/log-skalowania lub modeli odpornych na skrajne wartości.
- Korelacje między grupami wiekowymi mogą wskazywać na współliniowość; w modelach regresyjnych warto rozważyć redukcję wymiaru (PCA) lub selekcję cech.
- Tekst może dostarczać kontekstu i być źródłem cech uzupełniających – przez TF-IDF/tematy – jeśli da się go powiązać czasowo lub instytucjonalnie z danymi tabularnymi.

7. Rekomendacje i kolejne kroki

7.1. Preprocessing i przygotowanie cech

- Usunąć/wyłączyć kolumny QF lub pozostawić je tylko do audytu jakości.
- Zdecydować o obsłudze rekordów AllAges=0 (najczęściej usunięcie po weryfikacji).
- Dla outlierów: testowo porównać wyniki modeli dla (a) pełnych danych, (b) po winsoryzacji, (c) po log-transformacji.
- Zbudować wskaźniki struktury wieku (udział 65+, 75+, 85+) oraz tempo zmian w czasie na poziomie praktyki.

7.2. Tekst

- Doprecyzować jednostkę analizy (sekcja/akapit) i zapewnić spójny podział w każdym źródle.
- Wzmocnić czyszczenie: usunąć elementy nawigacyjne, źródła URL, stopki, numery stron.
- Rozważyć lematyzację oraz filtrację nazw własnych, jeśli nie są informacyjne.
- Jeżeli tekst ma być łączony z tabelami: zdefiniować mapowanie (czas, instytucja, region) i stworzyć cechy (TF-IDF/tematy) per okres/region.